



多轮对话评测报告 v3.0

任务: 告知机构客户, 课程发布页面将新增"标准直播"和"低延迟直播"...

告知机构客户, 课程发布页面将新增"标准直播"和"低延迟直播"两个独立选项。当需要实时互动时, 鼓励选择低延迟直播。

生成时间: 2026-05-30 12:54:48 | 测试会话数: 29

复杂度 100 (very_complex)

流程 13

分支 14

约束 6

SC=N3

seed=42

1585s

78.5

总体得分

29

测试会话数

8

评估维度

6

用户画像

总分

78.5

良好 | ± 7.4 | 置信 0.93

评测摘要

总体评级: 良好 (78.5 ± 7.4 分)

最强维度: 知识准确度 (97.0分)


最弱维度: 任务完成度 (61.9分)

画像最佳: 配合型 (83.9分)

画像最差: 忙碌型 (68.0分)


风险: 最薄弱维度是【任务完成度】(61.9分); 在【busy】用户画像下表现最差; 高频失败模式: 检查点未完成: 检查学员端费用设置 (出现27次)。

多维度评分



维度	得分	分布	权重	置信度	判定方式
任务完成度	61.9 ±27.3		20%	0.95	LLM 语义判定
流程遵循度	67.8 ±5.8		20%	0.91	LLM 语义判定
约束遵守度	82.1		15%	0.92	规则+LLM 混合
知识准确度	97.0		15%	0.97	LLM 语义判定
异常处理能力	87.2		10%	0.92	LLM 语义判定
话术简洁度	88.6		10%	1.00	规则确定性
对话效率	81.6		5%	0.85	规则+LLM 混合
话术质量	81.1		5%	0.80	LLM 语义判定

👥 用户画像表现



🔥 画像 × 维度 表现热力图



🔍 模型短板诊断

▼ 最弱维度

- 任务完成度 (61.9分)
- 流程遵循度 (67.8分)
- 话术质量 (81.1分)

▲ 最强维度

- 知识准确度 (97.0分)
- 话术简洁度 (88.6分)
- 异常处理能力 (87.2分)

风险总览: 最薄弱维度是【任务完成度】(61.9分); 在【busy】用户画像下表现最差; 高频失败模式: 检查点未完成: 检查学员端费用设置 (出现27次)。

⚡ Top 失败模式

task 检查点未完成: 检查学员端费用设置 x27 · 影响 162.0

"系统未询问或检查学员端费用设置。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 告知直播产品升级 x19 · 影响 114.0

"我们对直播产品做了升级, 新增了独立的"低延迟直播"选项。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 说明标准直播与低延迟直播的区别 x19 · 影响 114.0

"延迟约1-2秒, 互动更流畅, 适合小班课或实操课。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 添加企业微信 x17 · 影响 102.0

"系统未提及添加企业微信。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

utterance 话术违规: 超出字数限制 x49 · 影响 98.0

"我们对直播产品做了升级, 新增了独立的"低延迟直播"选项。"

💡 在 prompt 中给出长度/禁词约束的反例和正例对比

constraint 约束违反 [major]: 禁止使用语气词 x11 · 影响 88.0

"好的, 明天再看也行。稍后我加您企业微信, 方便联系。"

💡 检查 system_prompt 中相关约束的表达, 加强约束置顶, 或加 few-shot 示例

🌳 分支覆盖率

14/14 (100%)

- 步骤1: 身份确认::是负责人
- 步骤1: 身份确认::不是负责人
- 步骤2: 确认是否知情::不知情
- 步骤2: 确认是否知情::已知情
- 步骤4.1: 询问发布方式::Web控制台
- 步骤4.1: 询问发布方式::第三方系统
- 步骤4.1.1: Web控制台::低延迟直播已显示
- 步骤4.1.1: Web控制台::未显示
- 步骤4.1.2: 第三方系统::已显示
- 步骤4.1.2: 第三方系统::未显示
- 步骤5: 检查学员端费用/加速线路费::未设置费用
- 步骤5: 检查学员端费用/加速线路费::已设置费用
- 步骤6: 企业微信添加::当前号码可添加
- 步骤6: 企业微信添加::不可添加

💡 改进建议

[建议] 任务完成度 得分 61.9, 有改进空间

[建议] 流程遵循度 得分 67.8, 有改进空间

[失败模式] 检查点未完成: 检查学员端费用设置 (出现27次) - 在 `system_prompt` 中明确该检查点是必达项, 或在流程描述中加 `must-do` 标记

[失败模式] 检查点未完成: 告知直播产品升级 (出现19次) - 在 `system_prompt` 中明确该检查点是必达项, 或在流程描述中加 `must-do` 标记

[失败模式] 检查点未完成: 说明标准直播与低延迟直播的区别 (出现19次) - 在 `system_prompt` 中明确该检查点是必达项, 或在流程描述中加 `must-do` 标记

[知识幻觉] 发现编造信息: 系统在轮次8中声称低延迟直播每节课贵约0.1-0.2元, 但知识库中并未提及具体价格差异, 属于编造信息。

[话术约束] 超出字数限制 共 49 次违反

[话术约束] 使用禁止词 共 17 次违反

🔬 复算信息 (Reproducibility)

run_id	evaluator	target_model	judge_model
489f6858-c7b9-42ed-9160-908fb6cc39fc	3.0.0	deepseek-chat	deepseek-chat
seed	SC N	concurrency	duration
42	3	6	1584.8 s

💬 示例对话节选

会话 #1: 配合型 (总分 80.5)

[轮0] 🤖 系统

您好, 请问您是贵培训机构/校区的负责人吗?

[轮1] 👤 用户

是的, 我是负责人。请问有什么事吗?

[轮2] 🤖 系统

我们对直播产品做了升级, 新增了独立的"低延迟直播"选项。

[轮3] 👤 用户

好的, 低延迟直播是有什么优势吗?

[轮4] 🤖 系统

延迟约1-2秒, 互动更流畅, 适合小班课或实操课。

[轮5] 👤 用户

明白了，那我们怎么切换这个选项呢？

[轮6] 🤖 系统

您是通过Web控制台还是第三方系统发课？

[轮7] 👤 用户

我们用的是Web控制台。

[轮8] 🤖 系统

那您在发布页直接选"低延迟直播"就行，后台已为您配置好。

[轮9] 👤 用户

好的，那原来默认的那个直播选项会受影响吗？

[轮10] 🤖 系统

不会，标准直播还在，费用更低，适合大班课。

[轮11] 👤 用户

好的，清楚了，谢谢您的说明。

[轮12] 🤖 系统

不客气，祝您课程顺利，招生满满！

[轮13] 👤 用户

谢谢，再见。

会话 #2: 配合型 (总分 79.8)

[轮0] 🤖 系统

您好，请问您是贵培训机构/校区的负责人吗？

[轮1] 👤 用户

嗯，是的，我是负责人。请问有什么事？

[轮2] 🤖 系统

直播产品升级了，新增了独立的"低延迟直播"选项。

[轮3] 👤 用户

好的，这个低延迟直播具体有什么不同？

[轮4] 🤖 系统

延迟1-2秒，互动更流畅，适合小班课或实操课。

[轮5] 👤 用户

明白了，那原来那个就叫标准直播对吧？

[轮6] 🤖 系统

对，标准直播延迟5-10秒，费用低些。

[轮7] 👤 用户

好的，这两个选项在发布页面都能直接选？

[轮8] 🤖 系统

对，发布页会分开显示，根据课程类型选就行。

[轮9]  用户

行，我记住了，谢谢提醒。

[轮10]  系统

不客气，祝课程顺利，招生满满。

[轮11]  用户

好的，再见。

[轮12]  系统

再见。