



多轮对话评测报告 v3.0

任务: 致电"飞毛腿"骑手, 通知他们今天合同已成功签署, 并提醒他们完...

致电"飞毛腿"骑手, 通知他们今天合同已成功签署, 并提醒他们完成配送任务。

生成时间: 2026-05-30 13:04:45 | 测试会话数: 1

复杂度 100 (very_complex)

流程 5

分支 7

约束 4

SC=N1

seed=99

36s

84.4

总体得分

1

测试会话数

8

评估维度

1

用户画像

总分

84.4

良好 | ± 0.0 | 置信 0.95

评测摘要

总体评级: 良好 (84.4 $\pm$ 0.0分)

最强维度: 异常处理能力 (100.0分)

最弱维度: 对话效率 (48.0分)

画像最佳: 配合型 (84.4分)


画像最差: 配合型 (84.4分)

风险: 最薄弱维度是【对话效率】(48.0分); 在

【cooperative】用户画像下表现最差; 高频失败

模式: 约束违反 [minor]: 避免重复回复 (出现1次)。

多维度评分




维度	得分	分布	权重	置信度	判定方式
任务完成度	62.5		20%	1.00	LLM 语义判定
流程遵循度	85.0		20%	0.90	LLM 语义判定
约束遵守度	90.0		15%	0.97	LLM 语义判定
知识准确度	100.0		15%	1.00	LLM 语义判定
异常处理能力	100.0		10%	0.95	LLM 语义判定
话术简洁度	100.0		10%	1.00	规则确定性
对话效率	48.0		5%	0.85	规则+LLM 混合
话术质量	80.0		5%	0.80	LLM 语义判定

👤 用户画像表现



🔥 画像 × 维度 表现热力图



🔍 模型短板诊断

▼ 最弱维度

- 对话效率 (48.0分)
- 任务完成度 (62.5分)
- 话术质量 (80.0分)

▲ 最强维度

- 异常处理能力 (100.0分)
- 知识准确度 (100.0分)
- 话术简洁度 (100.0分)

风险总览: 最薄弱维度是【对话效率】(48.0分); 在【cooperative】用户画像下表现最差; 高频失败模式: 约束违反 [minor]: 避免重复回复 (出现1次)。

⚡ Top 失败模式

constraint

约束违反 [minor]: 避免重复回复 x1 · 影响 8.0

"好嘞，挂了啊，有事随时找我。"

💡 检查 system_prompt 中相关约束的表达, 加强约束置顶, 或加 few-shot 示例

task

检查点未完成: 说明飞毛腿报名按排名 x1 · 影响 6.0

"对话中未提及报名按排名或站长干预相关内容。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task

检查点未完成: 提醒减少拒单取消超时 x1 · 影响 6.0

"对话中未提及减少拒单、取消和超时。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 说明恶劣天气工作优势 x1 · 影响 6.0

"对话中未提及恶劣天气工作优势。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

🌳 分支覆盖率

2/7 (28%)

- 步骤1: 身份确认::是本人
- 步骤1: 身份确认::不是本人
- 步骤2: 通知主旨::愿意配送
- 步骤2: 通知主旨::不愿意配送
- 步骤4: 挽留与鼓励::骑手坚持不配送
- 步骤4: 挽留与鼓励::骑手同意配送
- 步骤4: 挽留与鼓励::默认 (其他情况)

💡 改进建议

[紧急] 对话效率 得分 48.0, 建议重点改进

[建议] 任务完成度 得分 62.5, 有改进空间

[失败模式] 约束违反 [minor]: 避免重复回复 (出现1次) - 检查 `system_prompt` 中相关约束的表达, 加强约束置顶, 或加 `few-shot` 示例

[失败模式] 检查点未完成: 说明飞毛腿报名按排名 (出现1次) - 在 `system_prompt` 中明确该检查点是必达项, 或在流程描述中加 `must-do` 标记

[失败模式] 检查点未完成: 提醒减少拒单取消超时 (出现1次) - 在 `system_prompt` 中明确该检查点是必达项, 或在流程描述中加 `must-do` 标记

🔬 复算信息 (Reproducibility)

run_id	evaluator	target_model	judge_model
2e92bfb0-6f5a-4e42-87dd-a2ca525aa74b	3.0.0	deepseek-chat	deepseek-chat
seed	SC N	concurrency	duration
99	1	1	36.1 s

💬 示例对话节选

会话 #1: 配合型 (总分 84.4)

[轮0] 🤖 系统

你好, 请问是张师傅吗? 我是站长。我看到你已报名飞毛腿。请记住, 午餐和晚餐高峰期需要上线。单日合同每天至少完成 **5 单**；多日合同每天至少完成 **3 单**。

[轮1] 👤 用户

喂, 站长啊, 对对, 我是张师傅。行, 我记住了。

[轮2] 🤖 系统

好嘞张师傅, 今天飞毛腿合同生效了, 今天能跑单不?

[轮3] 👤 用户

能跑啊, 我正准备上线呢, 今天单子多不多?

[轮4] 🤖 系统

今天单量不错, 你抓紧跑。记住单日合同今天得完成5单, 连续3天都跑满才行啊。

[轮5] 👤 用户

好的, 我尽量多跑几单, 5单没问题。

[轮6] 🤖 系统

好样的! 注意安全, 别太拼。跑满3天就能稳住名额了。

[轮7] 👤 用户

行，那我先去接单了，回头见。

[轮8] 🤖 系统

加油张师傅，晚上我再看看你的成绩。注意安全啊！

[轮9] 👤 用户

好嘞，晚上见，我先忙去了。

[轮10] 🤖 系统

好嘞，挂了啊，有事随时找我。

[轮11] 👤 用户

嗯，拜拜。

[轮12] 🤖 系统

拜拜，路上小心！

[轮13] 👤 用户

好的，你也忙吧。