

多轮对话评测报告 v3.0

任务: 告知机构客户, 课程发布页面将新增"标准直播"和"低延迟直播"...

告知机构客户, 课程发布页面将新增"标准直播"和"低延迟直播"两个独立选项。当需要实时互动时, 鼓励选择低延迟直播。

生成时间: 2026-05-30 11:54:49 | 测试会话数: 16

复杂度 100 (very_complex)

流程 13

分支 14

约束 7

SC=N1

seed=42

445s

82.0

总体得分

16

测试会话数

8

评估维度

3

用户画像

总分

82.0

良好 | ± 6.6 | 置信 0.94

评测摘要

总体评级: 良好 (82.0 ± 6.6 分)

最强维度: 知识准确度 (100.0分)


最弱维度: 任务完成度 (58.8分)

画像最佳: 配合型 (83.8分)

画像最差: 忙碌型 (68.2分)

风险: 最薄弱维度是【任务完成度】(58.8分); 在【busy】用户画像下表现最差; 高频失败模式: 话术违规: 超出字数限制 (出现41次)。

多维度评分




维度	得分	分布	权重	置信度	判定方式
任务完成度	58.8		20%	0.97	LLM 语义判定
流程遵循度	73.4		20%	0.89	LLM 语义判定
约束遵守度	95.0		15%	0.93	规则+LLM 混合
知识准确度	100.0		15%	0.97	LLM 语义判定
异常处理能力	92.2		10%	0.94	LLM 语义判定
话术简洁度	85.9		10%	1.00	规则确定性
对话效率	83.4		5%	0.85	规则+LLM 混合
话术质量	86.4		5%	0.80	LLM 语义判定

👤 用户画像表现



🔥 画像 × 维度 表现热力图



🔍 模型短板诊断

▼ 最弱维度

- 任务完成度 (58.8分)
- 流程遵循度 (73.4分)
- 对话效率 (83.4分)

▲ 最强维度

- 知识准确度 (100.0分)
- 约束遵守度 (95.0分)
- 异常处理能力 (92.2分)

风险总览: 最薄弱维度是【任务完成度】(58.8分); 在【busy】用户画像下表现最差; 高频失败模式: 话术违规: 超出字数限制 (出现41次)。

⚡ Top 失败模式

utterance 话术违规: 超出字数限制 x41 · 影响 82.0

"您之前选标准直播，后台其实已走低延迟线路，知道吗？"

💡 在 prompt 中给出长度/禁词约束的反例和正例对比

task 检查点未完成: 告知直播产品升级 x13 · 影响 78.0

"直播产品升级了，新增了低延迟直播选项。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 解释标准直播与低延迟直播的区别 x13 · 影响 78.0

"对话中未解释两者的延迟差异和适用场景。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 检查学员端费用设置 x12 · 影响 72.0

"对话中未询问用户是否已设置学员端费用或加速线路费。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 说明价格差异 x10 · 影响 60.0

"对话中未提及价格差异。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

task 检查点未完成: 添加企业微信 x9 · 影响 54.0

"对话中未提及企业微信添加事宜。"

💡 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记

分支覆盖率

14/14 (100%)

- 步骤1: 身份确认::是负责人
- 步骤1: 身份确认::不是负责人
- 步骤2: 确认是否知情::不知情
- 步骤2: 确认是否知情::已知情
- 步骤4.1: 询问发布方式::Web控制台
- 步骤4.1: 询问发布方式::第三方系统
- 步骤4.1.1: Web控制台::低延迟直播已显示
- 步骤4.1.1: Web控制台::低延迟直播未显示
- 步骤4.1.2: 第三方系统::已显示
- 步骤4.1.2: 第三方系统::未显示
- 步骤5: 检查学员端费用/加速线路费::未设置费用
- 步骤5: 检查学员端费用/加速线路费::已设置费用
- 步骤6: 企业微信添加::当前号码可添加
- 步骤6: 企业微信添加::当前号码不可添加

💡 改进建议

[紧急] 任务完成度 得分 58.8, 建议重点改进
[建议] 流程遵循度 得分 73.4, 有改进空间
[失败模式] 话术违规: 超出字数限制 (出现41次) - 在 prompt 中给出长度/禁词约束的反例和正例对比
[失败模式] 检查点未完成: 告知直播产品升级 (出现13次) - 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记
[失败模式] 检查点未完成: 解释标准直播与低延迟直播的区别 (出现13次) - 在 system_prompt 中明确该检查点是必达项, 或在流程描述中加 must-do 标记
[话术约束] 超出字数限制 共 41 次违反
[话术约束] 使用禁止词 共 4 次违反

🔍 复算信息 (Reproducibility)

run_id	evaluator	target_model	judge_model
d0cf6f56-68ed-4737-b14f-9ee3e9222972	3.0.0	deepseek-chat	deepseek-chat
seed	SC N	concurrency	duration
42	1	4	445.2 s

💬 示例对话节选

会话 #1: 配合型 (总分 74.8)

[轮0] 🤖 系统 您好, 请问您是贵培训机构/校区的负责人吗?
[轮1] 👤 用户 是的, 我是这里的负责人。
[轮2] 🤖 系统 直播产品升级了, 新增了低延迟直播选项。
[轮3] 👤 用户 好的, 这个升级主要有什么变化呢?
[轮4] 🤖 系统 发课时会多一个低延迟直播选项, 互动更流畅。
[轮5] 👤 用户 明白了, 那学生端是不是也要做相应调整?
[轮6] 🤖 系统 学生端不用动, 选低延迟就行。

[轮7] 用户

好的，那我们现在需要做什么准备吗？

[轮8] 系统

后台已为您开了低延迟，您直接选就行。

[轮9] 用户

好的，那我知道了，谢谢通知。

[轮10] 系统

不客气，祝您课程顺利。

[轮11] 用户

好的，再见。

会话 #2: 忙碌型 (总分 68.2)

[轮0] 系统

您好，请问您是贵培训机构/校区的负责人吗？

[轮1] 用户

嗯对，是我，什么事快说，我正忙着呢。

[轮2] 系统

就1分钟，保证简短。

[轮3] 用户

行，你说吧，我开车呢，捡重点说。

[轮4] 系统

那我稍后再打，安全第一。